

## 实验物理中的统计方法

$$\text{条件概率 } P(A|B) = \frac{P(A \cap B)}{P(B)}$$

相互独立:  $P(A) = P(A|B)$  即  $P(A \cap B) = P(A)P(B)$

主观概率(贝叶斯概率): 对假设为真的信心程度.

$$\text{贝叶斯定理 } P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$$\text{概率密度 pdf: } f(x) = \frac{P(x \in [x, x+dx])}{dx}$$

离散情形 pmf  $f(x_i) = p_i$ .

$$\text{cdf (累积分布函数)} \quad F(x) = \int_{-\infty}^x f(x') dx' = P(x' \leq x) \quad f(x) = \frac{\partial F(x)}{\partial x}$$

分位数  $x_\alpha$  定义为:  $F(x_\alpha) = \alpha$  ( $0 < \alpha < 1$ ).  $x_\alpha = F^{-1}(\alpha)$ . 中位数定义为  $x_{1/2} = F^{-1}(\frac{1}{2})$

众数: pdf 达最大值  $\frac{df}{dx} = 0$ .

$$\text{多维分布 联合概率密度 } f(x, y) = \frac{P(x \sim x+dx, y \sim y+dy)}{dx dy}$$

$$\text{条件概率 pdf: } h(y|x) = \frac{f(x, y)}{f_x(x)}$$

$$\text{边缘概率密度 } f_x(x) = \int f(x, y) dy = \frac{P(x \sim x+dx)}{dx}$$

$$\text{贝叶斯定理: } g(y|x) = \frac{h(y|x)}{f_y(y)}$$

若  $f(x, y) = f_x(x)f_y(y)$  即  $h(y|x) = f_y(y)$  则  $x, y$  相互独立.

## 随机变量函数的 pdf 问题

$$\text{函数 } a(x) \text{ 单调, 其 pdf 为 } g(a) \text{ 则 } g(a) da = \left| \int_{a(x)}^{a(x+da)} f(x') dx' \right| = \left| f[x(a)] \frac{dx}{da} \right| da \Rightarrow g(a)$$

$$\Rightarrow g(a) = \left| f[x(a)] \frac{dx}{da} \right|$$

若  $a(x)$  不单调, 需分段相加

另注: 根据 cdf 定义, 即  $P(Y \leq y) = P(g(x) \leq y) = P(x \leq g^{-1}(y))$  且  $g^{-1}(y)$  在  $x$  的区间上

$$\text{多维情形 } a = a(\vec{x}) \quad \vec{x} = (x_1, \dots, x_n)$$

$$\text{例: } z = xy. \quad g(z) dz = \iint_{\vec{x}} f(x, y) dx dy = \int_0^\infty dx \int_{\frac{z}{x}}^{\frac{z+dz}{x}} f(x, y) dy = \int_0^\infty \left[ f(x, \frac{z}{x}) \frac{dz}{x} \right] dx = \left[ \int_0^\infty f(x, \frac{z}{x}) \frac{dx}{x} \right] dz$$

$$\Rightarrow g(z) = \int_0^\infty f(x, \frac{z}{x}) \frac{dx}{x}$$

$$x, y > 0 \text{ 服从 } f(x, y) \quad \text{对 } z = x+y, \quad g(z) dz = \iint_{\vec{x}} f(x, y) dx dy = \int_0^\infty dx \int_{z-x}^{z+dx-x} f(x, y) dy$$

$$g(z) dz = \int_0^\infty dx \left[ f(x, z-x) dz \right] = \left[ \int_0^\infty f(x, z-x) dx \right] dz \Rightarrow g(z) = \int_0^\infty f(x, z-x) dx$$

$$\text{假设 } x, y \text{ 相互独立, 分别服从 } g(x) \text{ 与 } h(y), \text{ 则 } z = xy, \quad f(z) = \int_{-\infty}^\infty g(x) h\left(\frac{z}{x}\right) \frac{dx}{x} \quad (\text{梅林卷积, } f = g \otimes h)$$

$$z = x+y, \quad f(z) = \int_0^\infty g(x) h(z-x) dx \quad (\text{傅里叶卷积, } f = g \otimes h).$$

雅可比行列式. 构造  $n$  个双曲性无关函数  $\vec{a}(\vec{x}) = (a_1(\vec{x}), \dots, a_n(\vec{x}))$  其逆函数  $\vec{x}(\vec{a})$  存在. 则  $\vec{a}$  的联合 pdf 为:

$$g(\vec{a}) = |\det J| f(\vec{x}). \quad J = \frac{\det(D(x_1, \dots, x_n))}{\det(a_1, \dots, a_n)}$$

对  $g(\vec{a})$  积分掉其他不关心的变量, 可得任一边缘 pdf  $g_i(a_i)$ .

## 期待值、方差、标准差

$$\text{期待值 } E[x] = \int x f(x) dx \quad \text{常记为 } E[x] = \mu. \quad \text{可以证明 } E[a] = \int g(a) da = \int a f(x) dx$$

$$\text{方差 } V[x] = E[(x - E[x])^2] = E[x^2] - \mu^2. \quad \text{记为 } V[x] = \sigma^2. \quad \text{标准差 } \sigma = \sqrt{\sigma^2}.$$


$$\text{对多维情形, 定义协方差 } \text{cov}[x, y] \text{ (或 } \frac{\partial x \partial y}{\partial x \partial y} \text{)} = E[(x - \mu_x)(y - \mu_y)] = E[xy] - \mu_x \mu_y.$$

$$(协方差) 相关系数 \rho_{xy} = \frac{\text{cov}[x, y]}{\sigma_x \sigma_y} \quad \text{无量纲}, -1 \leq \rho_{xy} \leq 1$$

若  $x, y$  相互独立, 则  $\rho_{xy} = 0$  (反过来不一定)

秩相关性 更好度量相关性  $r_s = \rho_{R(x), R(y)}$  即先对  $X, Y$  进行排序 Spearman's rho


$$k\text{阶原点矩: } \mu_k = E[X^k] \quad k\text{阶中心矩: } \nu_k = E[(X - \mu)^k]$$



变异系数  $C_v = \frac{\sigma_x}{\mu_x}$  无量纲反映波动大小

偏度系数  $\rho_s = \frac{\nu_3}{\nu_2^{3/2}} = \frac{\nu_3}{\sigma^3}$  描述分布偏离对称性程度  $\rho_s > 0$  正偏/右偏  $\rho_s < 0$  负偏/左偏

峰度系数  $\rho_k = \frac{\nu_4}{\nu_2^2} - 3 = \frac{\nu_4}{\sigma^4} - 3$  (峰度) 描述分布的尖峭程度 正态分布  $\rho_k = 0$



特征函数  $\varphi(t) = E[e^{itX}] \quad -\infty < t < \infty$

连续变量  $\varphi(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx$  即 pdf 的傅里叶变换

性质  $|\varphi(t)| \leq \varphi(0) = 1$   $\varphi(-t) = \overline{\varphi(t)}$   $\varphi(aX+b) = \varphi_X(at+b) = e^{iba} \varphi_X(at)$

若  $X, Y$  独立,  $\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t)$

$$\varphi^{(k)}(0) = i^k E[X^k]$$

不确定度的传递 设  $y = y(\vec{x})$ . 已知  $\vec{x}$  的协方差矩阵  $V_{ij} = \text{cov}[x_i, x_j]$ .

将  $y$  在  $E[\vec{x}] = \bar{\vec{x}}$  线性展开, 得到  $V[y] = \sigma_y^2 \approx \sum_{i,j=1}^n \left[ \frac{\partial y}{\partial x_i} \frac{\partial y}{\partial x_j} \right]_{\vec{x}=\bar{\vec{x}}} V_{ij}$

若  $x_i$  不相关,  $V_{ij} = \sigma_i \sigma_j \delta_{ij}$ .  $\Rightarrow V[y] \approx \sum_{i=1}^n \left[ \frac{\partial y}{\partial x_i} \right]_{\vec{x}=\bar{\vec{x}}}^2 \sigma_i^2$

类似地, 对  $m$  组函数  $\vec{y}(\vec{x}) = (y_1(\vec{x}), \dots, y_m(\vec{x}))$ .  $V_{kl} = \text{cov}[y_k, y_l] \approx \sum_{i,j=1}^n \left[ \frac{\partial y_k}{\partial x_i} \frac{\partial y_l}{\partial x_j} \right]_{\vec{x}=\bar{\vec{x}}} V_{ij}$

$$\text{即 } V = A V A^T, \quad A_{ij} = \left[ \frac{\partial y_i}{\partial x_j} \right]_{\vec{x}=\bar{\vec{x}}}$$

局限: 只在  $y(\vec{x})$  为线性时成立, 严格成立, 若函数在  $\vec{x}$  范围内是非线性也不行.

正交变换消除相关性 对  $\vec{x} = (x_1, \dots, x_n)$  与  $V_{ij} = \text{cov}[x_i, x_j]$

作变换  $\vec{y} = A \vec{x}$ .  $V = A V A^T$  为对角阵.

二项分布  $f(n; N, p) = \frac{N!}{n!(N-n)!} p^n (1-p)^{N-n}$  即  $N$  次独立试验，每次成功概率  $p$ ，成功  $n$  次的概率。

$$E[n] = Np \quad V[n] = Np(1-p).$$

多项分布 有  $m > 2$  种结果，概率为  $p_1, \dots, p_m$   $N$  次试验结果用  $m$  维向量  $\vec{n} = (n_1, \dots, n_m)$  表示。其概率为：

$$f(\vec{n}; N, p) = \frac{N!}{n_1! n_2! \dots n_m!} p_1^{n_1} p_2^{n_2} \dots p_m^{n_m}.$$

$E[n_i] = Np_i, \quad V[n_i] = Np_i(1-p_i)$  可得协方差  $V_{ij} = Np_i(p_{ij} - p_j)$ 。即  $i \neq j$  时  $n_i$  与  $n_j$  相关。

泊松分布 考察  $N \rightarrow \infty, p \rightarrow 0$   $E[n] = Np \rightarrow \nu$  的二项分布极限。

$$f(n; \nu) = \frac{\nu^n}{n!} e^{-\nu}, \quad (n \geq 0) \quad \text{简记为 } \pi(\nu). \quad (\text{归一化 } \sum_{n=0}^{\infty} \frac{\nu^n}{n!} e^{-\nu} = 1).$$

$$E[n] = \nu \quad V[n] = \nu. \quad \text{即标准差是平均值开根号。著名的统计不确定度估计式 } \nu \pm \sqrt{\nu}.$$

均匀分布  $f(x; a, \rho) = \begin{cases} \frac{1}{\rho-a}, & a < x < \rho \\ 0, & \text{其他} \end{cases}$  简记为  $U(a, \rho)$ .

$$E[x] = \frac{1}{2}(a+\rho) \quad V[x] = \frac{1}{12}(\rho-a)^2$$

若  $F(x)$  为连续随机变量  $x$  的累积分布，则  $y = F(x)$  服从  $V(0, 1)$ 。（蒙特卡罗方法 - 反函数变换法）

指教分布  $f(x; \xi) = \begin{cases} \frac{1}{\xi} e^{-x/\xi}, & x \geq 0 \\ 0, & \text{其他} \end{cases}$  简记为  $Exp(\xi)$ .  $E[x] = \xi, \quad V[x] = \xi^2$ .

无记忆性： $f(t-t_0 | t \geq t_0) = f(t)$

高斯分布  $f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$  简记为  $N(\mu, \sigma^2)$   $E[x] = \mu \quad V[x] = \sigma^2$ .

标准正态分布  $N(0, 1)$   $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$   $\Phi(x) = \int_{-\infty}^x \varphi(x') dx'$

若  $x \sim N(\mu, \sigma^2)$  则  $y = \frac{x-\mu}{\sigma} \sim N(0, 1)$

中心极限定理  $n$  个独立随机变量  $x_i$ , 方差均存在, 则  $y = \sum_{i=1}^n x_i$ . 在  $n \rightarrow \infty$  下服从  $N(\mu, \sigma^2)$

$$\mu = \sum_{i=1}^n \mu_i \quad \sigma^2 = \sum_{i=1}^n \sigma_i^2.$$

泊松分布  $\nu$  较大时, 与高斯分布逐渐靠近。(实践中  $\nu \geq 5$ )

多维高斯分布  $f(\vec{x}; \vec{\mu}, V) = \frac{1}{(2\pi)^{\frac{n}{2}} |V|^{\frac{1}{2}}} \exp\left[-\frac{1}{2} (\vec{x} - \vec{\mu})^T V^{-1} (\vec{x} - \vec{\mu})\right]$   $E[x_i] = \mu_i \quad \text{cov}[x_i, x_j] = \nu_{ij}$

$$n=2 \text{ 时}, \quad f(x_1, x_2; \mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \left[ \left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 + \left(\frac{x_2-\mu_2}{\sigma_2}\right)^2 - 2\rho \left(\frac{x_1-\mu_1}{\sigma_1}\right) \left(\frac{x_2-\mu_2}{\sigma_2}\right) \right]\right)$$

$\rho = \frac{\text{cov}[x_1, x_2]}{\sigma_1 \sigma_2}$  是相关系数。对一维正态分布,  $\rho=0 \Leftrightarrow x_1, x_2$  相互独立。

卡方( $\chi^2$ )分布  $x_1, \dots, x_n$  是相互独立的服从  $N(\mu, N(0, 1))$ .  $\chi^2 = \sum_{i=1}^n x_i^2$ .

$\chi^2(\geq 0)$  服从  $\chi^2$  分布(自由度为  $n$ )  $f(\chi^2; n) = \frac{1}{2^{n/2} \Gamma(n/2)} \chi^{\frac{n}{2}-1} e^{-\chi^2/2}$  简记为  $\chi^2(n)$

$$E[\chi^2] = n \quad V[\chi^2] = 2n.$$

柯西分布  $f(x) = \frac{1}{\pi} \frac{1}{1+x^2}$

布来特-魏格纳分布  $f(x; \Gamma, x_0) = \frac{1}{\pi} \frac{\Gamma/2}{\Gamma^2/4 + (x-x_0)^2}$   $x_0$ : 模  $\Gamma$ : 半离全宽

$E[x]$  没有好的定义,  $V[x] \rightarrow \infty$ .

朗道分布  $f(x; \rho) = \frac{1}{\sqrt{\pi}} \phi(x)$   $(0 < x < 1)$

$\beta$  分布  $f(x; \alpha, \beta) = B(\alpha, \beta) x^{\alpha-1} (1-x)^{\beta-1}$ . 记为  $B(\alpha, \beta)$ .


$$E[x] = \frac{\alpha}{\alpha+\beta} \quad V[x] = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \quad B(1, 1) = U(0, 1).$$

Γ 分布  $f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \text{Ga}(\alpha, \beta) \quad (x > 0) \quad E[x] = \alpha\beta \quad V[x] = \alpha\beta^2$

逆氏分布  $f(x; \nu) = \frac{\Gamma(\nu+1)}{\sqrt{\pi} \Gamma(\nu/2)} \left(1 + \frac{x^2}{\nu}\right)^{-\nu/2} \text{记为 } t(\nu) \quad E[x] = 0, V[x] = \frac{\nu}{\nu-2}$

蒙特卡罗方法 变换法  $r \sim U(0, 1) \quad r = \int_{-\infty}^x f(x) dx \Rightarrow x = F^{-1}(r)$

舍选法 生成  $g(x)$  区域的随机分布点, 再舍选出  $f(x)$  区域的点.




假设 假设  $H$  可以预测数据的概率, 即观测的结果 (用  $x$  表示)  $x \sim f(x|H)$ . 简单假设 / 复合假设

给定  $H$  时  $x$  的概率称作假设  $H$  的似然值  $L(x|H)$ . (补充称为接受域)

若简单假设  $H_0$  和备择假设  $H_1$ , 对  $H_0$  的检验定义为: 对样本指定一个临界域  $W$  (拒绝域), 使得在  $H_0$  正确的情况下, 观测到该数据概率不超过某个(小)概率  $\alpha$ .  $P(x \in W|H_0) \leq \alpha$ . → 显著性水平 / 检验的大小.

第一类错误 (弃真错误) 假设  $H_0$  为真而被拒绝  $P(x \in W|H_0) \leq \alpha$



构造检验统计量  $n$  维数据空间  $x = (x_1, \dots, x_n)$  的临界域边界  $t(x_1, \dots, x_n) = t_{cut}$  其中  $t$  是一个标量  
检验统计量.  $\Rightarrow n$  维问题化为一维问题

若  $H_0$  为本底事例,  $H_1$  为信号事例. 本底选择效率:  $\alpha$  信号选择效率:  $1-\beta$

$$\text{信号纯度} = P(s|\bar{x} \in W) = \frac{P(\bar{x} \in W|s) P(s)}{P(\bar{x} \in W|s) P(s) + P(\bar{x} \in W|b) P(b)} = \frac{(1-\beta) P(s)}{(1-\beta) P(s) + \alpha P(b)} = 1 - \frac{\alpha P(b)}{(1-\beta) P(s) + \alpha P(b)}$$

信号选择效率

$$\text{信噪比} = \frac{P(s|\bar{x} \in W)}{P(b|\bar{x} \in W)} = \frac{1-\alpha}{\alpha} \frac{P(s)}{P(b)}$$

宽松选择：效率高，纯度低

严格选择：纯度高，效率低

奈曼-皮尔逊引理：在给定效率条件下，要得到最高纯度的信号样本，或在给定置信水平下得到最高

功效，可以选择下列接收法则实现： $\frac{g(t|H_0)}{g(t|H_1)} > c$ . ( $c$ 为常数，与效率有关)

对不含未知参数的最优化检验设计是为  $r = \frac{g(t|H_0)}{g(t|H_1)} \rightarrow$  简单假设  $H_0$  与  $H_1$  的似然比。

实际中  $r$  为单调函数为宜。奈-皮方法在多变量情形下不实用。

线性检验统计量 线性变换  $t(\bar{x}) = \sum_{i=1}^k a_i x_i = \vec{a}^\top \vec{x}$ ,  $T_k = \vec{a}^\top \vec{\mu}_k$ ,  $\Sigma_k^2 = \vec{a}^\top V_k \vec{a}$ ,  $k=0,1$ (假设)

费舍尔定义甄别函数  $J(\vec{a}) = \frac{(T_0 - T_1)^2}{\Sigma_0^2 + \Sigma_1^2}$  实际中要让  $|T_0 - T_1|$  尽可能大,  $\Sigma_0^2$  与  $\Sigma_1^2$  尽可能小。  
即  $J(\vec{a})$  尽可能大


令  $B = (\vec{\mu}_0 - \vec{\mu}_1)(\vec{\mu}_0 - \vec{\mu}_1)^\top$ ,  $W = V_0 + V_1$ , 则  $J(\vec{a}) = \frac{\vec{a}^\top B \vec{a}}{\vec{a}^\top W \vec{a}}$  令  $\frac{\partial J}{\partial a_i} = 0 \Rightarrow \vec{a} \propto W^{-1}(\vec{\mu}_0 - \vec{\mu}_1)$

将  $t(\bar{x})$  写成  $t(\bar{x}) = a_0 + \sum_{i=1}^k a_i x_i$  可以用  $a_0$  来固定  $T_0$  与  $T_1$ 。于是求  $J(\vec{a})$  最大值即最小化其分子

$$\Sigma_0^2 + \Sigma_1^2 = E_0(t - T_0)^2 + E_1(t - T_1)^2$$

p值 定义：观测到数据  $\bar{x}$  与假设  $H_1$  的符合程度不好于实测数据  $\bar{x}_{obs}$  与  $H_1$  的符合程度的概率。

显著性 Z：即  $p = \int_z^\infty \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$ .




查看别外效应：对信号位置的先验信息不足，普农效应后 p 值会变大。

皮尔逊卡方统计量 比较观测数据(实证):  $n_i$  与预期价值(模型)  $\hat{n}_i$  是否相符。( $n_i$ : 相互独立)

$$X^2 = \sum_{i=1}^n \frac{(n_i - \hat{n}_i)^2}{\hat{n}_i}, \quad \hat{n}_i = V[n_i]. \quad \text{若 } n_i \sim \pi(\hat{n}_i) \text{ 则 } V[n_i] = \hat{n}_i. \quad X^2 = \sum_{i=1}^n \frac{(n_i - \hat{n}_i)^2}{\hat{n}_i}$$

$f(x^2)$   $\downarrow$   $p = \int_{x^2}^\infty f(z; N) dz$ . 若  $n_i \sim N(\hat{n}_i, \sigma_i^2)$  或  $n_i \sim \pi(\hat{n}_i)$  且  $N_i \gg 1$ ,



评判估计量好坏 相合性(一致性)  $\lim_{n \rightarrow \infty} \theta = \theta$   $\lim_{n \rightarrow \infty} P(|\theta - \theta| > \epsilon) = 0, \forall \epsilon > 0$  成立

无偏性  $b = E[\theta] - \theta = 0$ .

有效性 对任何估计量  $\theta'$ , 有  $\lim_{n \rightarrow \infty} \frac{V[\theta_n]}{V[\theta']} \leq 1$ .

渐进有效性  $\theta_n$  为渐进有效估计量

$$\text{均方误差 MSE} = E[(\theta - \theta)^2] = V[\theta] + (E[\theta] - \theta)^2.$$

无偏估计量中方差最小的估计量为有效估计量。

均值的估计量 统计量：根据样本的函数（不含未知参数） 估计量：用来估计pdf的某些属性的统计量，记为 $\hat{\theta}$

估计量：估计量的观测值。

均值的估计量

$$\bar{x} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{样本均值})$$

若  $V[x_i]$  有限，不是与  $\mu$  相合的估计量，即  $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n x_i - \mu\right| \geq \varepsilon\right) = 0$  (弱大数定理)

无偏性： $E[\bar{x}] = E\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n} \sum_{i=1}^n E[x_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu$ .  $V[\bar{x}] = \sigma^2/n$ .

可以证明， $\bar{x}$  是  $\mu$  的有效估计量。

方差的估计量 假设均值  $\mu$  和方差  $V[\bar{x}] = \sigma^2$  都是未知量，样本方差定义为  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ .

$$s^2 = \frac{1}{n-1} \left[ \bar{x}^2 - \bar{x}^2 \right] \quad \text{因子 } \frac{1}{n-1} \text{ 保证 } s^2 \text{ 无偏}.$$

假设  $\mu = E[x]$  先验已知，则  $S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \bar{x}^2 - \bar{x}^2$ .  $S^2$  与  $s^2$  都是  $\sigma^2$  的无偏估计量。

$\sigma^2$  的方差  $V[S^2] = \frac{1}{n} \left[ \mu_4 - \frac{n-3}{n-1} \mu_2^2 \right]$   $K$  中心矩  $\mu_k$  估计： $\hat{\mu}_k = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^k$

协方差的估计量  $\hat{V}_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n-1} (\bar{xy} - \bar{x} \cdot \bar{y})$ . (无偏).

相关系数  $\rho = V_{xy}/(s_x s_y)$   $\Rightarrow \rho = r = \frac{\hat{V}_{xy}}{\sqrt{\hat{s}_x^2 \hat{s}_y^2}} = \frac{\bar{xy} - \bar{x} \cdot \bar{y}}{\sqrt{(\bar{x}^2 - \bar{x}^2)(\bar{y}^2 - \bar{y}^2)}}$   $r$  有偏倚。但  $n \rightarrow \infty$  时该偏倚趋于 0.

考虑样本  $\vec{x} = (x_1, \dots, x_n)$ ,  $x_i$  独立同分布,  $x_i \sim f(x; \theta)$  目标：估计  $\theta$ . 更一般地，估计  $\vec{\theta} = (\theta_1, \dots, \theta_m)$

若  $f(x; \theta)$  为真，则  $P(\text{观到第 } i \text{ 个数据处于 } [x_i, x_i + dx_i], \forall i = 1, \dots, n) = \prod_{i=1}^n f(x_i; \theta) dx_i$ .

定义似然函数  $L = \prod_{i=1}^n f(x_i; \theta)$   $\Rightarrow \theta$  使  $L$  取最大.  $\ln L(\theta)$  对数似然函数

最大似然估计量  $\hat{\theta} = \frac{\partial L(\theta)}{\partial \theta_i} = 0$ . 实际应用通常给出最好的实用解.

例外： $X \sim U(0, a)$   $\vec{x} = (x_1, \dots, x_n)$  则非最大似然法给出  $\hat{a} = \max\{x_1, \dots, x_n\}$  有偏倚

最大似然估计量的唯一性. 选取另一等价参数  $h(\theta)$ , 且  $\frac{\partial h}{\partial \theta} \neq 0$ , 则  $\hat{\theta} = h(\hat{\theta})$ .

信息不等式为任何估计量方差设定了下界  $V[\theta] \geq (1 + \frac{\partial b}{\partial \theta})^2 / E\left[-\frac{\partial^2 \ln L}{\partial \theta^2}\right]$   $\rightarrow$  最小方差界(MVB) (RCF 不成立),  $b$  为偏倚量  $E[\theta] - \theta$ .

如果  $b=0$  且等式成立，称  $\theta$  是有效估计量

通常  $b$  很小，等式近似成立,  $R$ :  $V[\theta] \approx -1/E\left[\frac{\partial^2 \ln L}{\partial \theta^2}\right]$

对于  $m$  个参数  $\vec{\theta} = (\theta_1, \dots, \theta_m)$  最小方差由 Fisher 信息矩阵给出:

$$I_{ij} = E\left[-\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j}\right] = -n \int f(x; \theta) \frac{\partial^2 \ln f(x; \theta)}{\partial \theta_i \partial \theta_j} dx.$$

信息不等式:  $V^{-1}$  是半正定矩阵, 其中  $V_{ij} = \text{cov}[\theta_i, \theta_j]$ . 因此  $V[\theta] \geq (I^{-1})_{ii}$ .

经常用  $I^{-1}$  近似协方差矩阵，并进一步估计:  $(V^{-1})_{ij} = -\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j} / \hat{\theta} = \hat{\theta}$ .

若单参数  $\theta$  的情况, 将  $\ln L(\theta)$  在  $\theta$  展开  $\ln L(\theta) = \ln L(\theta) + \frac{1}{2} \left[ \frac{\partial^2 \ln L}{\partial \theta^2} \right]_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2 + \dots$

$$\Rightarrow \ln L(\theta) \approx \ln L_{\max} - \frac{(\theta - \hat{\theta})^2}{2 \hat{\theta}^2} \quad \text{即 } \ln L(\theta + \hat{\theta}) \approx \ln L_{\max} - \frac{1}{2}.$$

$\Rightarrow$  为了得到  $\hat{\theta}_0$ , 让  $\theta$  偏离  $\hat{\theta}$ , 使得  $\ln L$  减小  $\approx 0.5$  (圆角法).

扩展的最大似然法。有时样本容量  $n \sim \pi(\theta)$ ，实验结果定义为  $n, x_1, \dots, x_n$

$$\text{则 } L(\nu, \theta) = \frac{\nu^n}{n!} e^{-\nu} \prod_{i=1}^n f(x_i; \theta). \quad \text{假设理论给出 } \nu = \nu(\theta). \quad \text{去掉与无关的项后.}$$

$$\ln L(\theta) = n \ln \nu(\theta) - \nu(\theta) + \sum_{i=1}^n \ln(f(x_i; \theta)) = -\nu(\theta) + \sum_{i=1}^n \ln[\nu(\theta) \cdot f(x_i; \theta)]$$

$$\text{假设 } \nu \text{ 与 } \theta \text{ 相互独立} \quad \frac{\partial L}{\partial \nu} = 0 \quad \Rightarrow \nu = n.$$

不等精度观测结果合并 对  $n$  次独立测量，结果为  $x_i \pm \sigma_i$ .  $\forall x_i \sim N(\mu, \sigma_i^2)$ .

$$L(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma_i^2}\right]. \quad \frac{\partial \ln L}{\partial \mu} = 0. \quad \Rightarrow \hat{\mu} = \frac{1}{\omega} \sum_{i=1}^n w_i x_i. \quad w_i = 1/\sigma_i^2.$$

$$\hat{\sigma}_\mu^2 = \left(-1/\frac{\partial^2 \ln L}{\partial \mu^2}\right)_{\mu=\hat{\mu}} = \frac{1}{\omega}. \quad \text{小于任何一个 } \sigma_i^2.$$

最小二乘法。设 Gauss 变量  $y_i$  ( $i=1, \dots, N$ )  $E[y_i] = \lambda_i = \lambda(x_i; \theta)$   $x_1, \dots, x_N \in V[y_i] = \sigma_i^2$  已知 估计  $\theta$

$$g(y_i; \lambda, \sigma^2) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \lambda_i)^2}{2\sigma^2}\right). \quad \ln L(\theta) = -\frac{1}{2} \sum_{i=1}^N \frac{(y_i - \lambda(x_i; \theta))^2}{\sigma^2}$$

$$\text{即求 } \chi^2(\theta) = \sum_{i=1}^N \frac{(y_i - \lambda(x_i; \theta))^2}{\sigma_i^2} \text{ 的最小值.}$$

最小二乘估计量 设  $y_i$  为多组 Gauss 变量，协方差矩阵为  $V$  已知.  $g(y_i; \lambda, V) = \frac{1}{(2\pi)^{N/2} \sqrt{|V|^{1/2}}} \exp\left(-\frac{1}{2}(y_i - \lambda)^T V^{-1} (y_i - \lambda)\right)$

$$\ln L(\theta) = -\frac{1}{2} \sum_{ij} [y_j - \lambda(x_i; \theta)] (V^{-1})_{ij} [y_j - \lambda(x_j; \theta)]. \quad \text{即求下式的最小值:}$$

$$\chi^2(\theta) = \sum_{ij=1}^N [y_j - \lambda(x_i; \theta)] (V^{-1})_{ij} [y_j - \lambda(x_j; \theta)]. \quad \text{其最小值定义了最小二乘估计量.}$$

即使  $y_i$  不是 Gauss 分布，该定义仍适用。

线性情况的最小二乘估计  $\lambda(x; \theta) = \sum_{j=1}^m a_j(x) \theta_j$  其中  $a_j(x)$  是  $x$  的任意线性独立函数

高斯-马尔科夫定理: 若没有偏倚，且得到的方差最小。

$$\because A_{ij} = a_j(x_i) \quad \chi^2(\theta) = (\bar{y} - \bar{\lambda})^T V^{-1} (\bar{y} - \bar{\lambda}) = (\bar{y} - A\bar{\theta})^T V^{-1} (\bar{y} - A\bar{\theta}).$$

$$\nabla \chi^2 = -2(A^T V^{-1} \bar{y} - A^T V^{-1} A \bar{\theta}) = 0. \quad \Rightarrow \bar{\theta} = (A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y} = B\bar{y}.$$

$$V_{ij} \triangleq \text{cov}[\theta_i, \theta_j] \quad \Rightarrow V = BVB^T = (A^T V^{-1} A)^{-1}$$

$$\text{由RCF定理: } \frac{\partial \chi^2}{\partial \theta_j} = -2 \frac{\partial (A^T V^{-1} \bar{y} - A^T V^{-1} A \bar{\theta})}{\partial \theta_j} = 2A^T V^{-1} A. \quad (V^{-1})_{ij} = \frac{1}{2} \left[ \frac{\partial^2 V^{-1}}{\partial \theta_i \partial \theta_j} \right]_{\theta=\bar{\theta}} = \sum_{k,l=1}^m a_k(x_k) (V^{-1})_{kl} a_l(x_l).$$

$\rightarrow$  若  $y_i$  是 Gauss 变量，其方差与 RCF 边界一致。

$$\chi^2(\theta) = \chi^2(\bar{\theta}) + \frac{1}{2} \sum_{ij=1}^m \left[ \frac{\partial^2 \chi^2}{\partial \theta_i \partial \theta_j} \right]_{\theta=\bar{\theta}} (\theta_i - \bar{\theta}_i)(\theta_j - \bar{\theta}_j) \quad \because \chi^2(\bar{\theta}) = \chi^2_{\min} \text{ 上式给出 } \chi^2(\bar{\theta} + \delta\theta) = \chi^2_{\min} + 1.$$

可把  $\chi^2(\theta) \leq \chi^2_{\min} + 1$  看作“置信区间”给出含真值  $\theta_0$  的可能性。

多项式的最小二乘拟合  $\lambda(x; \theta_0, \dots, \theta_m) = \sum_{j=0}^m \theta_j x^j$

若如果数据服从 Gauss 分布，那么  $\chi^2(\theta) = -2 \ln L(\theta)$  因此  $\hat{\theta} \approx -2 \left[ \frac{\partial^2 \chi^2}{\partial \theta^2} \right]_{\theta=\bar{\theta}}^{-1}$

\*或由图解法  $\chi^2(\theta_0 \pm \sigma_{\theta_0}) = \chi^2_{\min} + 1$

检验最小二乘法的拟合优度 假设  $y_i$  ( $i=1, \dots, N$ ) 为独立 Gauss 变量 ( $\sigma^2$  已知), 且  $\lambda(x; \theta)$  是  $y_i$  的函数  
函数. 那么  $\hat{\theta} = \theta^*$   $\Rightarrow \chi_{\min}^2 = \sum_{i=1}^N (y_i - \lambda(x_i; \hat{\theta}))^2$   $\chi_{\min}^2 \sim \chi^2(n_d)$ .  $n_d = N-m$ .  $m$  为参数个数.  
 $\chi^2$  可用作拟合优度统计量, 检验函数形式  $\lambda(x; \hat{\theta})$  的好坏. (单边检验).

拟合优度与统计不确定度的关系 统计不确定度小不意味着是一个好的拟合(反之亦然).

用最小二乘法合并实验结果 已知  $N$  个测量结果  $y_1, \dots, y_N$   $\sigma^2 = V[y_i]$  已知.

$$\text{若各测量互不相关 } \chi^2(\lambda) = \sum_{i=1}^N \frac{(y_i - \lambda)^2}{\sigma_i^2} \Rightarrow S = \sum_{i=1}^N w_i y_i. \quad w_i = \frac{1/\sigma_i^2}{\sum_{j=1}^N 1/\sigma_j^2} \quad V[\lambda] = \sum_{i=1}^N w_i \sigma_i^2.$$


$$\text{若各测量呈相关 } \text{cov}[y_i, y_j] = V_{ij}. \quad \chi^2(\lambda) = \sum_{i,j=1}^N (y_i - \lambda)(V^{-1})_{ij}(y_j - \lambda).$$

$$\Rightarrow \lambda = \sum_{i=1}^N w_i y_i. \quad w_i = \sum_{j=1}^N (V^{-1})_{ij} / \sum_{k,l=1}^N (V^{-1})_{kl}. \quad V[\lambda] = \sum_{i,j=1}^N w_i V_{ij} w_j.$$

LS方法得到无偏, 且方差最小 (高斯-马利夫定理)

箱线图

样本 p 分位数 ( $0 < p < 1$ ) 记为  $x_p$ , 至少有  $n_p$  个样本  $\leq x_p$  至少有  $n(1-p)$  个样本  $\geq x_p$



简单随机样本  $X_1, \dots, X_n$  独立同分布. 以后简称样本

对用不放回抽样代替放回抽样所得样本的代替条件:  $N/n \geq 10$ .  $N$  为总体中个体总数,  $n$  为样本容量.

抽样分布: 统计量  $T_n = g(X_1, \dots, X_n)$  的分布 (1)  $\chi^2$  分布 (2) t 分布 (3) F 分布 (4) 正态 总体样本均值和样本方差 F 分布 设  $X \sim \chi^2(n)$   $Y \sim \chi^2(m)$  且  $X, Y$  相互独立.  $\therefore F = \frac{X/n}{Y/m}$  其下限从第一自由度为  $n$ , 第二自由度为  $m$  的 F 分布.

密度为  $m$  的 F 分布.

性质: 1. 若  $F \sim F(n, m)$  则  $1/F \sim F(m, n)$ .

2.  $F_{1-\alpha}(n, m) = \frac{1}{F_\alpha(m, n)}$  其中  $F_\alpha(m, n)$  为  $F(m, n)$  的上  $\alpha$  分位数.

t 分布 设  $X \sim N(0, 1)$   $Y \sim \chi^2(n)$   $X, Y$  相互独立. 称  $T = \frac{X}{\sqrt{Y/n}}$  为服从自由度为  $n$  的 t 分布.

$n \rightarrow \infty$  时  $T$  分布  $\rightarrow N(0, 1)$ .

性质: 1°  $f_n(t)$  为偶函数  $n \rightarrow \infty f_n(t) \rightarrow \varphi(t)$ .

2° 满足  $P(|T| > t_{\alpha/2}) = \alpha$  的点  $t_{\alpha/2}$  称为 t 分布的双侧  $\alpha$  分位数.

正态总体样本均值和样本方差的分布 设总体  $X \sim N(\mu, \sigma^2)$ . 样本均值  $\bar{X} \sim N(\mu, \sigma^2/n)$ .

即  $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ .

样本方差分布 —  $\sigma^2$  已知

$$\frac{(n-1)s^2}{\sigma^2} = \sum_{i=1}^n \left( \frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi^2(n-1).$$

$\sigma^2$  未知但  $\mu$  已知 则  $\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1)$ .

围绕某固定值  $x_0$  的  $k$  阶矩 / 简单矩  $\mu_k = \int (x - x_0)^k f(x) dx$   $x_0 = 0$  时称为  $k$  阶原点矩  $\mu'_k$  或  $\mu_k'$

$x_0 = E[x] = \mu$  时称为  $k$  阶中心矩  $\mu_k$ .

原点矩与中心矩关系:  $\mu_k = \sum_{i=0}^k \binom{k}{i} \mu'_{k-i} (-\mu')^i$ ,  $\mu'_k = \sum_{i=0}^k \binom{k}{i} \mu_{k-i} (\mu')^i$ .

矩的一般表达. 设  $x \sim f(x; \theta)$ , 构造  $m$  个线性的多项式函数  $a_i(x)$ .

$$E[a_i(x)] = \int a_i(x) f(x; \theta) dx = e_i(\theta) \quad (\text{矩的一般表达式})$$

其中  $e_i(\theta)$  可用无偏样本均值估计  $\bar{e}_i = \bar{a}_i = \frac{1}{n} \sum_{j=1}^n a_i(x_j)$ . 令  $e_i(\theta) = \bar{a}_i$  则  $\theta$  通过求解  $m$  个  $e_i(\theta)$  方程来确定.

常见选择:  $a_i = x^i$   $E[a_i(x)] = \mu'_i$   $i$  阶原点矩.

置信区间. 设  $\theta$  为待估参数, 对于给定实数  $\alpha$  ( $0 < \alpha < 1$ ), 存在两个统计量  $T_1(x_1, \dots, x_n)$  与  $T_2(x_1, \dots, x_n)$

若对  $\forall \theta \in \Theta$ , 有  $P(T_1 \leq \theta \leq T_2) \geq 1 - \alpha$  称随机区间  $[T_1, T_2]$  为  $\theta$  的置信水平为  $1 - \alpha$  的置信区间或区间估计.  $T_1$  称为(双侧)置信下限,  $T_2$  称为(双侧)置信上限.

若上式可以取等, 称  $[T_1, T_2]$  为  $\theta$  的  $1 - \alpha$  同态置信区间.

枢轴量: 仅含 1 个参数的样本的连续函数且分布不依赖于未知参数. 如  $\frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$  其中  $\sigma$  已知.

单尾置信区间. 使两个尾部概率各为  $\alpha/2$ .

高斯分布估计量的置信区间. 若不服从  $f(x; \theta) = \frac{1}{\sqrt{2\pi\sigma_\theta^2}} \exp\left(-\frac{(x-\theta)^2}{2\sigma_\theta^2}\right)$  求  $\theta$  的置信区间

Jeffrey's 验前概率  $\pi(\theta) \propto \det(I(\theta))$  其中  $I(\theta)$  是 Fisher 信息矩阵

$$I_{ij}(\theta) = -E\left[\frac{\partial^2 \ln L(\bar{x}|\theta)}{\partial \theta_i \partial \theta_j}\right] = -\int \frac{\partial^2 \ln L(\bar{x}|\theta)}{\partial \theta_i \partial \theta_j} L(\theta \mid \bar{x}) d\bar{x}$$

这样的验前概率选择给出的推断在参数变换下不变.

$$\bar{x} \sim N(\mu, \sigma^2). \quad \pi(\mu) \propto \frac{1}{\mu}. \quad n \sim \pi(\mu) \quad \pi(\mu) \sim \frac{1}{\mu}.$$